

Segmentación automática de estructuras dentales en radiografías panorámicas para apoyo en el análisis morfológico

Daniela Flores Casillas, Marie Jose Pérez Peralta, Larissa Airy Eguino Montoya, Yira Itzae Rendón Hernández

Student IDs: A01541538, A01352442, A0174162, A01352483

School of Biomedical Engineering, Tecnológico de Monterrey, Campus Guadalajara, México

Abstract— La segmentación automática de estructuras dentales en radiografías panorámicas representa un desafío debido a la superposición de tejidos anatómicos, las variaciones de contraste y las diferencias morfológicas entre pacientes. En este trabajo se desarrolló e implementó un modelo de segmentación semántica basado en la arquitectura U-Net para identificar estructuras dentales en radiografías panorámicas. Se utilizó el conjunto de datos público “Panoramic Dental X-Ray Dataset”, compuesto por imágenes anotadas en formato COCO, divididas en 42 imágenes para entrenamiento, 12 para validación y 6 para prueba. Las anotaciones fueron convertidas a máscaras binarias y las imágenes fueron normalizadas y redimensionadas a una resolución de 512 x 1024 píxeles antes del entrenamiento. El desempeño del modelo se evaluó mediante las métricas Dice e Intersección sobre Unión (IoU). Los resultados obtenidos mostraron un coeficiente Dice de 0.849 y un IoU de 0.737 sobre el conjunto de prueba, evidenciando una adecuada capacidad para segmentar estructuras dentales. Adicionalmente, se realizó una validación exploratoria con radiografías externas no incluidas en el conjunto de entrenamiento, observándose una correcta identificación de la mayoría de las estructuras dentales, aunque con la presencia de falsos positivos en regiones óseas adyacentes. Los resultados demuestran que la arquitectura U-Net constituye una herramienta viable para el análisis automático de radiografías panorámicas y puede servir como base para futuros sistemas de apoyo al diagnóstico odontológico asistido por inteligencia artificial.

Index Terms— *Radiografía panorámica, segmentación semántica, U-Net, aprendizaje profundo, procesamiento de imágenes médicas, odontología digital.*

I. INTRODUCCIÓN

Las radiografías panorámicas dentales constituyen una de las herramientas de imagen más utilizadas en la práctica odontológica debido a su capacidad para proporcionar una visualización integral de ambas arcadas dentales, la mandíbula, el maxilar y diversas estructuras anatómicas asociadas en una sola adquisición radiográfica [1]. Estas imágenes son empleadas rutinariamente para la evaluación del desarrollo dental, la detección de anomalías morfológicas, el análisis de terceros molares impactados y la planificación de tratamientos odontológicos.

A pesar de su utilidad clínica, la interpretación manual de radiografías panorámicas continúa siendo un proceso complejo debido a la presencia de ruido, variaciones en el contraste,

superposición de estructuras anatómicas y diferencias morfológicas entre pacientes. Estas características pueden dificultar la delimitación precisa de las piezas dentales y generar variabilidad entre observadores, especialmente en estudios con gran cantidad de imágenes.

En los últimos años, los avances en aprendizaje profundo han impulsado el desarrollo de métodos automáticos para la segmentación de imágenes médicas. Entre ellos, las redes neuronales convolucionales han demostrado un desempeño sobresaliente en tareas de segmentación semántica [4], destacando particularmente la arquitectura U-Net por su capacidad para preservar información espacial y generar segmentaciones precisas incluso cuando se dispone de conjuntos de datos relativamente pequeños [5].

La segmentación automática de dientes representa una etapa fundamental para sistemas posteriores de clasificación, detección de anomalías y análisis morfológico asistido por computadora. Al aislar las estructuras dentales del resto de la imagen, es posible facilitar la identificación de dientes retenidos, supernumerarios, ausencias dentales y otras alteraciones anatómicas relevantes para la práctica clínica [2], [3].

El objetivo de este trabajo fue desarrollar e implementar un modelo de segmentación semántica [4] basado en U-Net para la identificación automática de estructuras dentales en radiografías panorámicas. Asimismo, se evaluó el desempeño del modelo mediante métricas cuantitativas de segmentación y se analizó su capacidad preliminar de generalización utilizando imágenes externas no incluidas durante el entrenamiento.

II. ESTADO DEL ARTE

La segmentación de imágenes médicas constituye una de las aplicaciones más relevantes del aprendizaje profundo debido a su capacidad para identificar automáticamente estructuras anatómicas de interés y facilitar procesos de diagnóstico asistido por computadora. Tradicionalmente, la segmentación se ha abordado mediante técnicas de procesamiento clásico de imágenes, como umbralización, detección de bordes, filtros espaciales y operaciones morfológicas. Aunque estos métodos son interpretables y tienen bajo costo computacional, su desempeño suele disminuir cuando las imágenes presentan bajo contraste, ruido, superposición anatómica o variaciones importantes entre

pacientes.

La arquitectura U-Net, propuesta por Ronneberger et al. [5], representó un avance importante en segmentación biomédica debido a su estructura codificador-decodificador y al uso de conexiones de salto. Estas conexiones permiten recuperar información espacial de alta resolución durante la reconstrucción de la máscara, lo cual resulta especialmente útil en imágenes médicas donde los bordes anatómicos son relevantes.

En odontología, la segmentación automática ha cobrado importancia debido a la creciente disponibilidad de radiografías digitales y al interés por desarrollar sistemas de apoyo al diagnóstico clínico. Las radiografías panorámicas permiten observar simultáneamente ambas arcadas dentales, el maxilar, la mandíbula y estructuras anatómicas relacionadas; sin embargo, su análisis puede complicarse por la superposición de estructuras, la variabilidad anatómica y las diferencias de adquisición entre equipos radiográficos [1].

Da Silva Rocha y Endo [6] realizaron una comparación de modelos de aprendizaje profundo para segmentación dental en radiografías panorámicas, observando que las arquitecturas basadas en redes convolucionales presentan mejor desempeño que los métodos clásicos cuando se dispone de imágenes anotadas. Este tipo de estudios demuestra que el aprendizaje profundo puede identificar patrones anatómicos complejos que no siempre son capturados por filtros o métodos de umbralización convencionales.

Otros trabajos han explorado arquitecturas más especializadas para segmentación dental. Zhang et al. [7] propusieron redes basadas en Mask-Transformer para segmentar dientes en radiografías panorámicas. Este enfoque permite combinar información global y local, además de favorecer tareas de segmentación por instancia, donde cada pieza dental puede distinguirse individualmente. No obstante, estos modelos suelen requerir mayor cantidad de datos, mayor capacidad de cómputo y procesos de entrenamiento más complejos que una U-Net clásica.

Zannah et al. [9] evaluaron arquitecturas U-Net para segmentación semántica en radiografías panorámicas dentales, mostrando que este tipo de redes puede adaptarse adecuadamente a la delimitación automática de estructuras dentales. Estos enfoques pueden alcanzar métricas superiores a las de una U-Net convencional, pero también incrementan la complejidad arquitectónica y el costo computacional.

De manera similar, Brahmi y Jdey [11] abordaron la segmentación e identificación automática de dientes en radiografías panorámicas mediante redes convolucionales profundas, lo que refuerza la viabilidad de utilizar modelos supervisados para análisis dental automatizado. Este tipo de aproximaciones permite avanzar hacia sistemas más completos, capaces no solo de segmentar estructuras dentales, sino también de clasificarlas o identificarlas anatómicamente.

Las revisiones sistemáticas recientes han señalado que los métodos basados en aprendizaje profundo superan consistentemente a las técnicas tradicionales en tareas de detección y segmentación dental. Sin embargo, también reportan limitaciones importantes, como la disponibilidad reducida de datos anotados, la falta de validación multicéntrica, la variabilidad entre equipos radiográficos y la dificultad para generalizar a imágenes externas

[10], [12], [13].

Con base en estos antecedentes, el presente trabajo propone la implementación de una arquitectura U-Net clásica para la segmentación semántica de estructuras dentales en radiografías panorámicas. A diferencia de enfoques más complejos basados en Transformers o segmentación por instancia, este proyecto busca evaluar una solución reproducible, de complejidad moderada y adecuada para un conjunto reducido de datos. La principal área de oportunidad se encuentra en analizar si una U-Net convencional, acompañada de un preprocesamiento adecuado y una resolución de entrada suficiente, puede obtener resultados aceptables con menor costo computacional y menor complejidad de implementación.

A partir de la literatura revisada, se observa que los métodos clásicos de procesamiento de imágenes, como la umbralización, detección de bordes y operaciones morfológicas, presentan la ventaja de ser interpretables y de bajo costo computacional. Sin embargo, su desempeño disminuye ante imágenes con bajo contraste, ruido, superposición anatómica y variabilidad entre pacientes.

Por otro lado, las arquitecturas basadas en aprendizaje profundo, especialmente U-Net y sus variantes, han demostrado mayor capacidad para aprender características anatómicas complejas y segmentar estructuras dentales con mayor precisión. No obstante, estos métodos requieren imágenes anotadas, mayor capacidad de cómputo y pueden presentar dificultades para generalizar cuando el conjunto de entrenamiento es limitado.

Los modelos más recientes basados en Transformers y arquitecturas híbridas permiten capturar relaciones globales y locales dentro de la imagen, lo que puede mejorar la segmentación de estructuras dentales complejas. Sin embargo, su implementación suele requerir mayor cantidad de datos, mayor tiempo de entrenamiento y recursos computacionales superiores.

Con base en lo anterior, el área de oportunidad identificada en este proyecto consiste en evaluar si una arquitectura U-Net clásica, acompañada de un preprocesamiento adecuado y una resolución de entrada suficiente, puede obtener un desempeño competitivo en segmentación dental panorámica con menor complejidad computacional y menor esfuerzo de implementación que modelos más avanzados.

Tabla I. Comparación estado del arte

Trabajo	Método	Ventaja	Desventaja
Ronneberger et al.	U-Net	Buena segmentación con pocos datos	Menor capacidad global que Transformers
Da Silva Rocha y Endo	Modelos DL	Mejor desempeño que métodos clásicos	Requiere imágenes anotadas
Zhang et al.	Mask-Transformer	Captura información local y global	Mayor costo computacional
Zannah et al.	Variantes U-Net	Buen desempeño en radiografías panorámicas	Mayor complejidad arquitectónica
Brahmi y Jdey	CNN profundo	Segmentación e identificación dental	Requiere más entrenamiento
Propuesta	U-Net clásica	Menor complejidad y buena reproducibilidad	Limitada por tamaño del dataset.

III. DESCRIPCIÓN DE LOS DATOS UTILIZADOS

Para el desarrollo y evaluación del modelo de segmentación se utilizó el conjunto de datos público Panoramic Dental X-Ray Dataset, diseñado para tareas de segmentación e identificación automática de dientes en radiografías panorámicas. Este conjunto de datos incluye imágenes panorámicas digitales obtenidas mediante sistemas radiográficos odontológicos especializados y cuenta con anotaciones manuales realizadas por expertos para delimitar las estructuras dentales presentes en cada imagen.

El dataset se encuentra organizado en diferentes subconjuntos. Para este trabajo se utilizó la sección destinada a segmentación semántica, la cual contiene imágenes panorámicas acompañadas de anotaciones en formato COCO (Common Objects in Context). Dichas anotaciones describen mediante polígonos la ubicación de las estructuras dentales presentes en cada radiografía, permitiendo generar máscaras binarias utilizadas como referencia durante el entrenamiento supervisado del modelo.

Tabla II. Dataset

Subconjunto	Número de imágenes	Uso
Entrenamiento	42	Ajuste de pesos del modelo
Validación	12	Monitoreo del aprendizaje y early stopping
Prueba	6	Evaluación final del desempeño

Las imágenes originales presentan variaciones en tamaño, contraste y características anatómicas. Con el objetivo de estandarizar el proceso de entrenamiento, todas las imágenes fueron convertidas a escala de grises, normalizadas en un rango de intensidad entre 0 y 1 y redimensionadas a una resolución de 512×1024 píxeles. Paralelamente, las anotaciones COCO fueron transformadas en máscaras binarias donde los píxeles correspondientes a estructuras dentales fueron etiquetados como primer plano y el resto de la imagen como fondo.

La utilización de un conjunto de datos público favorece la reproducibilidad de los resultados y permite comparar el desempeño obtenido con trabajos previos reportados en la literatura. Sin embargo, debido al número limitado de imágenes disponibles para entrenamiento, el conjunto también representa un escenario adecuado para analizar la capacidad de aprendizaje de arquitecturas U-Net bajo condiciones de disponibilidad restringida de datos.

IV. PROPUESTA GENERAL DE SOLUCIÓN

La solución desarrollada consiste en un sistema de segmentación semántica basado en aprendizaje profundo para identificar automáticamente estructuras dentales en radiografías panorámicas. El objetivo principal del sistema es generar una máscara binaria que permita separar las piezas dentales del resto de las estructuras anatómicas presentes en la imagen.

El pipeline implementado inicia con la carga de las radiografías panorámicas y de sus correspondientes anotaciones en formato COCO. A partir de dichas anotaciones se generaron máscaras binarias utilizadas como referencia durante el entrenamiento supervisado. Posteriormente, las imágenes fueron convertidas a escala de grises, normalizadas y redimensionadas a una resolución uniforme de 512×1024 píxeles para garantizar la consistencia de los datos de entrada.




Figura 1. Flujo general del sistema propuesto para la segmentación automática de estructuras dentales en radiografías panorámicas.

El pipeline implementado inicia con la carga de las radiografías panorámicas y sus anotaciones en formato COCO. Posteriormente, las anotaciones poligonales son convertidas en máscaras binarias, donde los píxeles pertenecientes a estructuras dentales se etiquetan como primer plano y el resto de la imagen como fondo. Después, las imágenes son convertidas a escala de grises, normalizadas y redimensionadas a una resolución uniforme de 512×1024 píxeles.

La normalización de intensidades se realizó para llevar los valores de los píxeles al rango $[0,1]$, de acuerdo con:

$$I_{norm} = \frac{I}{255} \quad (1)$$

donde I representa la imagen original e I_{norm} la intensidad normalizada. Esta etapa permite reducir la variabilidad de intensidad entre imágenes y facilita el entrenamiento de la red neuronal.

La arquitectura U-Net utilizada está compuesta por una etapa de codificación, un cuello de botella y una etapa de decodificación. En la etapa de codificación, las capas convolucionales extraen características locales de la imagen, mientras que las capas de Max Pooling reducen progresivamente la dimensionalidad espacial y permiten capturar información más abstracta. La operación de Max Pooling puede representarse como:

$$y = \max(x_i) \quad (2)$$

donde y corresponde al valor máximo dentro de una ventana local de activación.

Posteriormente, en la etapa de decodificación, las capas de UpSampling recuperan progresivamente la resolución espacial de la imagen. Las conexiones de salto permiten combinar información profunda con información espacial de alta resolución proveniente del encoder, mejorando la delimitación de los contornos dentales.

La salida del modelo utiliza una función sigmoide para asignar a cada píxel una probabilidad de pertenecer a la clase dental:

$$\sigma(x) = \frac{1}{1+e^{-x}} \quad (3)$$

Finalmente, la imagen de probabilidad es convertida en una máscara binaria mediante un umbral de decisión. Los píxeles con

probabilidad superior al umbral son clasificados como estructura dental, mientras que los valores inferiores son clasificados como fondo.

$$M(x, y) = \begin{cases} 1, & \text{si } \sigma(x, y) \geq T \\ 0, & \text{si } \sigma(x, y) < T \end{cases} \quad (4)$$




Figura 2. Arquitectura simplificada de la red U-Net utilizada para la segmentación de estructuras dentales.

Matemáticamente, la operación fundamental utilizada por la red es la convolución bidimensional:

$$(I * K)(x, y) = \sum_m \sum_n I(x - m, y - n) K(m, n) \quad (5)$$

donde (I) representa la imagen de entrada y (K) corresponde al kernel de convolución utilizado para extraer características relevantes.

El entrenamiento se realizó utilizando una función de pérdida basada en Dice Loss, optimizada mediante el algoritmo Adam con una tasa de aprendizaje inicial de 0.0001. Se empleó Early Stopping para evitar sobreajuste y se utilizaron conjuntos independientes de validación y prueba para evaluar la capacidad de generalización del modelo.

Tabla III. Configuración experimental del modelo

Parámetro	Valor
Arquitectura	U-Net
Imágenes de entrenamiento	42
Imágenes de validación	12
Imágenes de prueba	6
Resolución de entrada	512 x 1024
Batch size	2
Tasa de aprendizaje	0.0001
Optimizador	Adam
Función de pérdida	Dice Loss
Épocas máximas	60
Early stopping	Sí

Además de los parámetros de entrenamiento, se documentaron aspectos relacionados con la implementación computacional del modelo. Esta información permite evaluar la complejidad de la propuesta y comparar su costo computacional con arquitecturas más avanzadas reportadas en la literatura.

Tabla IV. Configuración computacional del modelo

Parámetro	Valor
Framework	TensorFlow/Keras
Arquitectura	U-Net
Resolución	512 x 1024
Batch size	2
Learning rate	0.0001
Epochs máximas	60
Parámetros entrenables	1,946,305
Tamaño del modelo	7.42 MB
Callbacks	EarlyStopping, ReduceLROnPlateau, ModelCheckpoint

La configuración empleada demuestra que la propuesta posee una complejidad computacional moderada. En comparación con

arquitecturas más recientes basadas en mecanismos de atención o Transformers, el modelo utilizado puede entrenarse utilizando recursos computacionales accesibles, manteniendo al mismo tiempo un desempeño competitivo para la segmentación de estructuras dentales.

Finalmente, las máscaras generadas por la red fueron comparadas con las máscaras de referencia mediante métricas cuantitativas de segmentación, principalmente el coeficiente Dice y la Intersección sobre Unión (IoU), permitiendo medir objetivamente el desempeño alcanzado por el sistema.

El orden de las funciones dentro del pipeline es fundamental para obtener una segmentación adecuada. Primero, la conversión de las anotaciones COCO a máscaras binarias permite establecer la referencia supervisada contra la cual se entrena el modelo. Posteriormente, la normalización debe realizarse antes del entrenamiento para asegurar que las intensidades de las radiografías se encuentren en un rango homogéneo. El redimensionamiento previo a la entrada de la red permite que todas las imágenes tengan dimensiones consistentes.

Después del preprocesamiento, las capas convolucionales extraen características locales como bordes, contornos y patrones de textura. Las capas de Max Pooling reducen la resolución espacial y permiten que el modelo aprenda características más generales. En la etapa de decodificación, el UpSampling recupera la resolución de la imagen y las conexiones de salto reincorporan detalles espaciales importantes para preservar los bordes dentales.

Si este orden se altera, el desempeño del modelo puede verse afectado. Por ejemplo, entrenar sin normalización puede dificultar la convergencia; redimensionar de forma inadecuada puede eliminar detalles anatómicos finos; y omitir las conexiones de salto puede reducir la precisión en los contornos de las estructuras dentales.

V. MÉTRICAS DE EVALUACIÓN

El desempeño del modelo de segmentación fue evaluado mediante métricas ampliamente utilizadas en segmentación semántica de imágenes médicas. Estas métricas permiten cuantificar el grado de coincidencia entre las máscaras predichas por el modelo y las máscaras de referencia obtenidas a partir de las anotaciones del conjunto de datos.

La principal métrica utilizada fue el coeficiente Dice, el cual mide el nivel de superposición entre dos regiones segmentadas. Matemáticamente se define como:

$$Dice = \frac{2TP}{2TP + FP + FN} \quad (6)$$

donde (TP) representa los verdaderos positivos, (FP) los falsos positivos y (FN) los falsos negativos. Un valor cercano a 1 indica una alta similitud entre la segmentación generada por el modelo y la máscara de referencia.

Adicionalmente, se utilizó la métrica Intersección sobre Unión (Intersection over Union, IoU), definida por:

$$IoU = \frac{TP}{TP + FP + FN} \quad (7)$$

Esta métrica cuantifica la proporción de píxeles correctamente segmentados respecto al total de píxeles pertenecientes a la unión de ambas regiones.

Durante el entrenamiento se empleó una función de pérdida basada en Dice Loss, expresada como:

$$DiceLoss = 1 - Dice \quad (8)$$

La utilización de Dice Loss resulta especialmente adecuada para problemas de segmentación médica debido a que penaliza directamente la falta de superposición entre las regiones segmentadas y las regiones de referencia.

Finalmente, para complementar el análisis del desempeño se consideró la pérdida de validación (Validation Loss) como indicador del comportamiento del modelo durante el proceso de aprendizaje y como criterio para la aplicación de técnicas de Early Stopping destinadas a reducir el riesgo de sobreajuste.

Los resultados finales obtenidos sobre el conjunto de prueba fueron un coeficiente Dice de 0.849, un valor IoU de 0.737 y una pérdida final de 0.151, indicando una adecuada capacidad del modelo para identificar estructuras dentales en radiografías panorámicas.

VI. RESULTADOS

El modelo U-Net fue entrenado utilizando 42 imágenes del conjunto de entrenamiento y evaluado mediante conjuntos independientes de validación y prueba. Durante el entrenamiento se observó una disminución progresiva de la función de pérdida y un incremento sostenido de las métricas de segmentación, lo que indica una convergencia adecuada del proceso de aprendizaje.




Figura 3. Curvas de entrenamiento del modelo U-Net. Se observa una disminución progresiva de la función de pérdida y un incremento sostenido del coeficiente Dice, lo que evidencia la convergencia del modelo durante el proceso de aprendizaje.

La evaluación final realizada sobre el conjunto de prueba produjo los resultados mostrados en la Tabla III.

Tabla V. Resultados finales obtenidos sobre el conjunto de prueba.

Métrica	Valor
Dice	0.849

IoU	0.737
Loss	0.151



Figura 4. Ejemplo de segmentación dental obtenida con el modelo U-Net sobre una imagen del conjunto de prueba. La comparación entre la radiografía original, la máscara de referencia, la predicción y la superposición muestra la capacidad del modelo para delimitar estructuras dentales con coherencia anatómica.

Estos resultados indican que el modelo logró una segmentación consistente de las estructuras dentales en el conjunto de prueba. El coeficiente Dice de 0.849 sugiere una alta superposición entre la máscara predicha y la máscara de referencia, mientras que el IoU de 0.737 confirma que la mayor parte de la región dental fue correctamente identificada. En comparación con la configuración de menor resolución, el incremento a 512×1024 píxeles permitió preservar mejor los contornos radicales, espacios interdientales y detalles anatómicos finos.

Con el objetivo de analizar la influencia de la resolución de entrada sobre el desempeño del modelo, se realizaron experimentos utilizando dos configuraciones distintas. La Tabla IV muestra la comparación obtenida.

Tabla VI. Comparación del desempeño según la resolución utilizada.

Resolución	Dice	IoU
256 x 512	0.595	0.424
512 x 1024	0.849	0.737

Los resultados demuestran que el incremento de la resolución permitió preservar detalles anatómicos finos, mejorando significativamente la capacidad de segmentación de la red neuronal.

Adicionalmente, se realizó una validación exploratoria utilizando radiografías panorámicas externas que no pertenecían al conjunto de entrenamiento ni al conjunto de prueba. En estas imágenes el modelo fue capaz de identificar adecuadamente la mayor parte de las estructuras dentales, incluyendo terceros molares impactados y variaciones anatómicas no observadas explícitamente durante el entrenamiento. Sin embargo, también se observaron falsos positivos en regiones óseas adyacentes, particularmente en estructuras de alto contraste radiográfico.

Estos resultados sugieren que el modelo presenta una capacidad preliminar de generalización hacia imágenes externas, aunque todavía requiere entrenamiento con conjuntos de datos más amplios y diversos para mejorar su robustez clínica.

VII. DISCUSIÓN

Los resultados obtenidos demuestran que la arquitectura U-Net posee una capacidad adecuada para segmentar estructuras dentales en radiografías panorámicas. El coeficiente Dice de 0.849 y el valor IoU de 0.737 indican una alta coincidencia entre las máscaras generadas automáticamente y las máscaras de referencia utilizadas durante la evaluación.

Uno de los hallazgos más relevantes del estudio fue la influencia de la resolución de entrada sobre el desempeño del modelo. Inicialmente se evaluó una configuración de 256×512 píxeles, obteniéndose un Dice de 0.595 y un IoU de 0.424. Posteriormente, al incrementar la resolución a 512×1024 píxeles, las métricas mejoraron considerablemente hasta alcanzar un Dice de 0.849 y un IoU de 0.737. Este comportamiento sugiere que la preservación de detalles anatómicos finos, particularmente los espacios interdentes y los contornos radiculares, resulta fundamental para lograr una segmentación precisa.

Los resultados visuales mostraron que el modelo fue capaz de identificar correctamente la mayoría de las coronas y raíces dentales presentes en las radiografías panorámicas. Asimismo, las predicciones obtenidas sobre imágenes de prueba presentaron una distribución anatómica coherente con las máscaras de referencia, lo que indica que la red neuronal logró aprender características relevantes asociadas a las estructuras dentales y no únicamente patrones específicos de entrenamiento.

Como parte de la validación exploratoria, se evaluó el modelo con radiografías panorámicas externas que no pertenecían al conjunto de entrenamiento, validación o prueba. En dichas imágenes, la red fue capaz de segmentar estructuras dentales principales e incluso piezas con variaciones anatómicas, como terceros molares impactados o dientes adicionales. Este resultado sugiere que el modelo no se limita únicamente a reproducir patrones observados en el conjunto de entrenamiento, sino que aprendió características visuales asociadas a estructuras dentales. Sin embargo, también se observaron falsos positivos en regiones óseas adyacentes y zonas de alto contraste, lo que evidencia que el modelo aún no discrimina de manera perfecta entre tejido dental y estructuras anatómicas con apariencia radiográfica similar.




Figura 5. Resultado de segmentación sobre una radiografía panorámica externa no utilizada durante el entrenamiento, validación o prueba del modelo.

Este comportamiento sugiere que el modelo aprendió adecuadamente características relacionadas con los dientes, aunque todavía presenta dificultades para diferenciar completamente entre tejido dental y otras estructuras anatómicas con características radiográficas similares. Dicha limitación es consistente con lo reportado en la literatura para modelos entrenados con conjuntos de datos reducidos [10], [12].

En comparación con trabajos previos basados en U-Net para segmentación dental panorámica, los resultados obtenidos demuestran que incluso una arquitectura U-Net clásica puede alcanzar un desempeño competitivo cuando se emplea una

estrategia adecuada de preprocesamiento y una resolución de entrada suficiente para preservar la información anatómica relevante.

En comparación con enfoques más complejos reportados en la literatura, como modelos basados en Transformers o variantes avanzadas de U-Net, la propuesta desarrollada presenta una ventaja en términos de simplicidad, reproducibilidad y menor costo de implementación. Aunque es posible que arquitecturas más recientes alcancen métricas superiores, estas suelen requerir mayor cantidad de datos anotados, mayor memoria GPU y tiempos de entrenamiento más prolongados. Por ello, el desempeño obtenido en este trabajo resulta relevante, ya que demuestra que una U-Net clásica puede alcanzar resultados adecuados para segmentación dental panorámica cuando se emplea una resolución suficiente y un preprocesamiento consistente.

VIII. LIMITACIONES Y TRABAJO FUTURO

A pesar de los resultados obtenidos, el presente estudio presenta diversas limitaciones que deben considerarse al interpretar los hallazgos.

La principal limitación corresponde al tamaño del conjunto de datos utilizado para entrenamiento. Aunque el modelo logró alcanzar métricas satisfactorias de segmentación, únicamente se dispuso de 42 imágenes para entrenamiento, lo cual restringe la diversidad anatómica disponible durante el proceso de aprendizaje y puede limitar la capacidad de generalización del sistema ante poblaciones más amplias.

Otra limitación importante es que todas las imágenes utilizadas durante el entrenamiento, validación y prueba provienen del mismo conjunto de datos. Si bien se realizó una validación exploratoria utilizando radiografías externas, esta evaluación no constituye una validación clínica formal ni permite garantizar un desempeño equivalente en imágenes adquiridas mediante diferentes equipos radiográficos o protocolos de adquisición.

Asimismo, se observaron falsos positivos en estructuras óseas y regiones anatómicas adyacentes a las piezas dentales. Este fenómeno sugiere que el modelo todavía presenta sensibilidad a características radiográficas compartidas entre diferentes tejidos, por lo que podrían requerirse conjuntos de entrenamiento más amplios o arquitecturas más avanzadas para mejorar la discriminación anatómica.

Aunque durante las pruebas exploratorias el modelo fue capaz de segmentar piezas dentales adicionales o con posiciones anatómicas poco comunes, el sistema no cuenta con la capacidad de clasificarlas automáticamente como dientes supernumerarios o anomalías dentales. Esto se debe a que el entrenamiento se planteó como un problema de segmentación binaria, donde únicamente se distingue entre fondo y estructura dental, sin diferenciar entre tipos de dientes o alteraciones clínicas específicas. Además, aunque el conjunto de datos contiene algunos casos con variaciones anatómicas, estos no son suficientemente numerosos ni están etiquetados como una clase independiente para entrenar un modelo robusto de clasificación de anomalías.

Como trabajo futuro se propone incrementar el tamaño y diversidad del conjunto de datos mediante la incorporación de radiografías provenientes de distintas instituciones y sistemas de

adquisición. También se plantea evaluar arquitecturas más recientes como Attention U-Net, U-Net++ y modelos basados en Transformers, así como implementar técnicas avanzadas de aumento de datos y validación multicéntrica.

Finalmente, una línea de investigación de interés consiste en extender el sistema hacia tareas de clasificación y detección automática de anomalías dentales, incluyendo dientes supernumerarios, agenesias, erupciones anómalas y alteraciones morfológicas específicas, utilizando la segmentación desarrollada en este trabajo como etapa inicial de procesamiento.

Las posibles líneas de trabajo futuro presentan diferentes beneficios potenciales, pero también implican costos computacionales, requerimientos de datos y desafíos de implementación. La Tabla V resume estas consideraciones.

Tabla VII. Trabajo Futuro

Trabajo futuro	Beneficio esperado	Costo o desventaja
Aumentar el dataset	Mejor generalización	Requiere más anotaciones manuales
Validación multicéntrica	Mayor robustez clínica	Requiere imágenes de distintos equipos
Attention U-Net	Mejor enfoque en regiones dentales	Mayor complejidad computacional
U-Net++	Mejor recuperación de detalles	Más parámetros y tiempo de entrenamiento
Transformers	Mejor contexto global	Alto costo de GPU y más datos
Clasificación de anomalías	Apoyo diagnóstico más completo	Requiere etiquetas clínicas específicas

IX. CONCLUSIONES

En este trabajo se desarrolló e implementó un sistema de segmentación semántica basado en la arquitectura U-Net para la identificación automática de estructuras dentales en radiografías panorámicas. El modelo fue entrenado utilizando un conjunto de datos público anotado en formato COCO y evaluado mediante métricas estándar de segmentación ampliamente utilizadas en imágenes médicas.

Los resultados obtenidos demostraron que la arquitectura propuesta fue capaz de segmentar estructuras dentales con un coeficiente Dice de 0.849 y un valor IoU de 0.737, evidenciando una elevada concordancia entre las máscaras predichas y las anotaciones de referencia. Asimismo, se comprobó experimentalmente que la resolución de entrada tiene un impacto significativo en el desempeño del modelo, observándose una

mejora sustancial al preservar una mayor cantidad de información anatómica durante el entrenamiento.

La validación realizada sobre radiografías externas mostró que el sistema posee una capacidad preliminar de generalización y puede identificar correctamente estructuras dentales incluso en presencia de variaciones anatómicas no observadas explícitamente durante el entrenamiento. Sin embargo, también se identificaron limitaciones asociadas a falsos positivos en regiones óseas y a la disponibilidad limitada de datos para entrenamiento.

En conjunto, los resultados obtenidos confirman que las arquitecturas basadas en aprendizaje profundo constituyen una herramienta prometedora para la automatización del análisis de radiografías panorámicas. Aunque el sistema desarrollado no pretende reemplazar el criterio clínico del especialista, sí demuestra potencial como herramienta de apoyo para mejorar la visualización, organización y análisis inicial de estructuras dentales en entornos académicos y clínicos.

X. REPOSITORIO GITHUB

REFERENCIAS

- [1] Różyło-Kalinowska, “Panoramic radiography in dentistry,” *Clinical Dentistry Reviewed*, vol. 5, no. 26, Dec. 2021, doi: 10.1007/s41894-021-00111-4.
- [2] A. H. Demiriz, T. Durmuşlar, and M. Misir, “Investigation of impacted supernumerary teeth: a cone beam computed tomograph (CBCT) study,” *Journal of Istanbul University Faculty of Dentistry*, vol. 51, no. 3, pp. 18–24, 2017, doi: 10.17096/jiufd.20084.
- [3] A. S. Alhazmi, A. Alzahrani, and A. Alzahrani, “Incidental Pathologic Findings from Orthodontic Pretreatment Panoramic Radiographs,” *Children*, vol. 10, no. 2, Art. no. 262, Feb. 2023, doi: 10.3390/children10020262.
- [4] S. Minaee, Y. Boykov, F. Porikli, A. Plaza, N. Kehtarnavaz, and D. Terzopoulos, “Image Segmentation Using Deep Learning: A Survey,” *IEEE Transactions on Pattern Analysis and Machine Intelligence*, vol. 44, no. 7, pp. 3523–3542, Jul. 2022, doi: 10.1109/TPAMI.2021.3059968.
- [5] O. Ronneberger, P. Fischer, and T. Brox, “U-Net: Convolutional Networks for Biomedical Image Segmentation,” in *Medical Image Computing and Computer-Assisted Intervention – MICCAI 2015*, Cham, Switzerland: Springer, 2015, pp. 234–241, doi: 10.1007/978-3-319-24574-4_28.
- [6] É. da Silva Rocha and P. T. Endo, “A Comparative Study of Deep Learning Models for Dental Segmentation in Panoramic Radiograph,” *Applied Sciences*, vol. 12, no. 6, Art. no. 3103, Mar. 2022, doi: 10.3390/app12063103.
- [7] Y. Zhang, W. Li, X. Chen, J. Zhang, and Y. Wang, “Mask-Transformer-Based Networks for Teeth Segmentation in Panoramic Radiographs,” *Diagnostics*, vol. 13, no. 14, Art. no. 2365, Jul. 2023, doi: 10.3390/diagnostics13142365.

- [8] M. Kanwal, M. M. U. Rehman, M. U. Farooq, and D. Chae, "Mask-Transformer-Based Networks for Teeth Segmentation in Panoramic Radiographs," *Bioengineering*, vol. 10, no. 7, Art. no. 843, Jul. 2023, doi: 10.3390/bioengineering10070843.
- [9] R. Zannah, M. Bashar, R. B. Mushfiq, A. Chakrabarty, S. Hossain, and Y. J. Jung, "Semantic Segmentation on Panoramic Dental X-Ray Images Using U-Net Architectures," *IEEE Access*, vol. 12, pp. 44598–44612, 2024, doi: 10.1109/ACCESS.2024.3380027.
- [10] W. Brahmi, I. Jdey, and F. Drira, "Exploring the role of Convolutional Neural Networks (CNN) in dental radiography segmentation: A comprehensive systematic literature review," *Engineering Applications of Artificial Intelligence*, vol. 133, Art. no. 108510, 2024, doi: 10.1016/j.engappai.2024.108510.
- [11] W. Brahmi and I. Jdey, "Automatic tooth instance segmentation and identification from panoramic X-Ray images using deep CNN," *Multimedia Tools and Applications*, vol. 83, no. 18, pp. 55565–55585, 2024, doi: 10.1007/s11042-023-17568-z.
- [12] M. Bonfanti Gris, A. Herrera, M. P. S. Rodríguez-Manzanique, F. Martínez-Rus, and G. Pradies, "Deep learning for tooth detection and segmentation in panoramic radiographs: a systematic review and meta-analysis," *BMC Oral Health*, vol. 25, Art. no. 1280, 2025, doi: 10.1186/s12903-025-06349-9.
- [13] J. Peng and Y. Wang, "Medical Image Segmentation With Limited Supervision: A Review of Deep Network Models," *IEEE Access*, vol. 9, pp. 36827–36851, 2021, doi: 10.1109/ACCESS.2021.3062380.
- [14] *Checking your browser - reCAPTCHA*. (s. f.-b). <https://www.kaggle.com/datasets/orvile/panoramic-dental-xray-dataset>